

自己進化 AI を「証明」で守る

llcore 研究知見 2026 — 検証付きニューラル進化 (CPU 完結)

Kazufumi Furuse

github.com/furuse-kazufumi/llcore (paper draft + 全実験コード/データ公開)

本スライド: CC BY 4.0 — 出典明示で商用利用可

問題: 自己進化 AI は何を根拠に自分の変更を許可するか


AI が自分のコア (記憶・力学) を書き換えながら進化する時代

主流 (DGM / SEAL 系) = 経験的ゲート: スコアや過去の失敗で事後判定


構造的弱点: ① 死んで学ぶ ② Goodhart 可能 (指標ハック)

llcore: 性質を絞れば「数学的証明」が評価の前のゲートになる

経験的ゲート (DGM/SEAL 系)



証明ゲート (llcore)



証明できない変更は評価前に却下 (fail-closed)

アプローチ: 健全な収縮証明ゲート (fail-closed)

証明する性質 = 収縮 ($\rho < 1$): 内部状態が発散しない

証明は定理の帰結 = 捏造不能 (スコアと違いハックできない)

進化ループ内・評価前に gate — 事後検証より 17-19 倍安い

全実験は事前登録 → 結果の順。negative も全強度で開示

健全 certifier の 3 段ラダー (下ほど強い)

閉形式 ∞ -norm — $O(n^2)$ ・ソルバ不要

頂点 2-norm (SVD)

Lyapunov SDP (CLARABEL)


証明なし → 不採用 (fail-closed)

実験場: 死ねる環境 × 経験が記憶になる 3 つの道

環境が再帰ゲイン κ を 2 倍にステップ → 旧安全個体が発散
= 死

死は回避不能な実在の脅威 (入力側の工夫では逃げられない設計)

測定は助走後の定常状態 ($n=20$ シード, 事前登録)



ENDO
自己予見 (証明)

REVIVE
死→修復→復活

OBSERVE
他者の死から学ぶ


+ baseline: NONE (無防備) / EXO (設計時固定ゲート)

知見 1: 証明は死ぬ前に分かる — 定常死ゼロ

証明 (ENDO) は致命的評価を完全にゼロ化

観察学習は機能する — が、学んでも死が残る (17.3)。「死んで学ぶ」は構造コスト

12/12 の事前登録環境 (シード/ κ /次元/課題難度) で頑健
記憶獲得能力は犠牲にならない (最大適応度差 0.7%)



致命的評価数 (定常状態, linear 基質, $n=20$ 平均) — 一次データ: results_viability_ab.json

$p < 0.001$ (paired sign-flip, $n=20$)


知見 2: 復活がないと、経験は記憶にならない

死 = 個体の除去 = 蓄積した経験 (遺伝子) も消える

REVIVE は無防備と同程度死ぬのに、集団記憶が有意に高い

$\Delta = +0.060$ ($p = 0.0011$) — 修復が記憶チャネルを保つ
たまま力学を安全化

死が「消滅」でなく「傷」になる



集団平均適応度 (linear 基質)。縦軸は 0.60 開始 (差の可視化のため; 効果量に注意)


知見 3: 証明 1 つは、経験的機構の積み重ねに勝る

3 機構の全 8 組合せを同条件で比較 (2^3 factorial)

証明 (E) を含む 4 組合せ: すべて死 0.0

証明なしの最良 = 復活+観察 (6.2)。単独より良いが、0 には届かない

証明があると経験的機構は完全に冗長化 (交互作用 $p=0.0003/0.0045$)



致命的評価数 (2^3 factorial, linear, $n=20$ 平均)。E=証明 / R=復活 / O=観察

知見 4 (限界): 証明は前提が正しい時だけ健全


検証器の環境認識を壊すと、証明は致命域を「安全」と誤認する

観測可能な証拠だけで証明 $\leftrightarrow$ 経験を切替える信頼度学習は機能する (図)

ただし得をするのは前提違反が高くつく環境のみ — 仮説の一部不成立をそのまま報告

次の問い: 証明の前提を誰が守るのか (premise monitoring)

検証器が κ を 40% 過小推定 (premise 破壊)
→ 証明が嘘をつく regime を人工的に構成



META の証明への信頼度 (平均, linear)。「許可したのに死んだ」だけから regime を追従

PoC スケール (スカラー遺伝子, $n=20$) — 実 LLM スケールは未証明

研究地図: 最近接研究との違い (一次ソース検証済み)

SGM: 統計的 certificate × 離散タスク性能 — 確率保証・捏造耐性なし

SEVerA: Dafny 論理契約の sound 検証 — 対象は離散 I/O

PAC limits (Wang+): 汎化保証 — 安定性の保証ではない

右上の象限 (証明 × 連続記憶力学) を Ilcore が PoC 占有

対象 ↑ 連続な内部力学 / ↓ 離散タスク・成果物



保証: ← 統計的/経験的 | 健全な証明 (演繹) →

3 論文とも本文を一次取得して確認 (敵対検証付き)

利用について

本スライド: CC BY 4.0 — 出典明示で、企業内研修・技術調査・製品検討に利用可

コード/論文 draft: Apache-2.0 + Commercial dual license

クローズド統合・SLA・NDA 相談 = 商用窓口:
kazufumi@furuse.work

出典表記例: 「Kazufumi Furuse, llcore (2026),
github.com/furuse-kazufumi/llcore」

github.com/furuse-kazufumi/llcore

qiita.com/furuse-kazufumi

商用ライセンス窓口
kazufumi@furuse.work