

自己進化 AI を「証明」で守る

llcore 研究知見 2026 — 検証付きニューラル進化 (CPU 完結)

Kazufumi Furuse

github.com/furuse-kazufumi/llcore (paper draft + 全実験コード/データ公開)

本スライド: CC BY 4.0 — 出典明示で商用利用可

問題: 自己進化 AI は「何を根拠に」自分の変更を許可するか

AI が自分のコア (記憶・力学) を書き換えながら進化する時代 — 危険な変更をどう弾くか
主流 (DGM / SEAL 系) = 経験的ゲート: ベンチマークスコアや過去の失敗で判断
経験的ゲートの構造的弱点: ① 死んで学ぶ (失敗コストを払う) ② Goodhart 可能 (指標ハック)
llcore の問い: 性質を絞れば「数学的証明」でゲートできるのではないか

アプローチ: 健全な収縮証明ゲート (fail-closed)

証明する性質 = 収縮 ($\rho < 1$): 内部状態が発散しない・記憶力学が暴走しない

3 段の健全 certifier: 閉形式 ∞ -norm ($O(n^2)$) $\rightarrow$ 頂点 2-norm $\rightarrow$ Lyapunov SDP

fail-closed: 証明できない変更は通さない。証明は定理の帰結 = 捏造不能

進化ループ内で評価前に gate (prove-then-reject) — 事後検証の 17-19 倍安い

全証明・全実験は事前登録 $\rightarrow$ 結果の順で記録 (research/paper/PAPER_DRAFT.md)

実験場:「死ねる環境」×「経験が記憶になる 3 つの道」

環境が再帰ゲイン κ を 2 倍にステップ → それまで安全だった個体が発散 = 死

ENDO (自己予見): 内的な健全証明で死を予見し、評価前に自分を弾く

REVIVE (復活修復): 死を経験するが、記憶遺伝子を保ったまま安全側に修復され蘇る

OBSERVE (社会的観察): 他個体の死の近傍を経験的に避ける (経験的ゲートの代表)

n=20 シード・事前登録・助走後の定常統計で測定 (negative も全部開示)

知見 1: 証明は死ぬ前に分かる — 定常死ゼロ

致命的評価の数 (定常状態, linear 基質):

無防備 27.2 / 観察学習 17.3 / 固定ゲート 10.2 / 証明 (ENDO) 0.0

観察学習は機能する — しかし学んでも死が残る。「死んで学ぶ」は構造コスト

頑健性: シード・κ 強度・次元・課題難度を変えた 12/12 環境で証明側の優位が保持
しかも証明ゲートは記憶獲得能力を犠牲にしない (最大適応度差 0.7%)

$p < 0.001$ (paired sign-flip, $n=20$)。数値はすべて results_viability_*.json (公開)

知見 2: 復活がないと、経験は記憶にならない

死 = 個体の除去 = その個体が蓄積した経験 (遺伝子) も消える

REVIVE は無防備と同程度死ぬのに、集団に残る記憶 (平均適応度) が有意に高い

集団平均適応度: 無防備 0.649 → 復活あり 0.708 ($\Delta = +0.060$, $p = 0.0011$)

修復は「記憶チャンネルを保ったまま力学だけ安全化」— 死が傷として記憶に刻まれる

知見 3: 証明 1 つは、経験的機構の積み重ねに勝る

3 機構の全 8 組み合わせを同条件で比較 (2^3 factorial):

証明 (E) を含む 4 組み合わせ: 全て死 0.0

証明なしの最良 = 復活+観察 (RO): 6.2 — 単独 (18.8 / 17.3) より良いが 0 には届かない

証明があると経験的機構の死削減効果は消える (交互作用 $p=0.0003/0.0045$) = 完全に冗長化

経験的機構は重ねるほど良い — ただし証明が使えない世界での話

知見 4 (限界): 証明は「前提が正しい時」だけ健全

検証器が環境 (κ) を 40% 過小推定する状況を作ると、証明は致命域を「安全」と誤認
観測可能な信号 (「許可したのに死んだ」) だけで証明 $\Leftrightarrow$ 経験を切替える信頼度学習は可能
ただし得をするのは前提違反が高くつく環境のみ — 安い環境では常時証明が最適 (事前登録の仮説が一部
不成立、そのまま報告)
次の研究課題: 「証明の前提を誰が守るのか」(premise monitoring)

PoC スケール (スカラー遺伝子, $n=20$) — 実 LLM スケールは未証明。誇張しない

研究地図: 最近接研究との違い (一次ソース検証済み)

SGM (統計的ゲーデルマシン): 統計的 certificate × 離散タスク性能 — 確率保証・捏造耐性なし

SEVerA: 論理契約 (Dafny) の sound 検証 — 対象は離散 I/O、連続な内部力学ではない

自己改善の PAC 限界 (Wang et al.): 汎化保証 — 安定性・収縮の保証ではない

空白 = 「連続な記憶力学を、進化ループ内で、健全な収縮証明でゲートする」— Ilcore が PoC 占有

3 論文とも本文を一次取得し敵対検証済み。詳細対比は論文 related work 節

利用について

本スライド: CC BY 4.0 — 出典明示で、企業内研修・技術調査・製品検討にそのまま利用可
コード/論文 draft: Apache-2.0 + Commercial dual license (github.com/furuse-kazufumi/llcore)

クローズド統合・SLA・NDA 付き相談 = 商用ライセンス窓口: kazufumi@furuse.work

記事 (日本語解説): qiita.com/furuse-kazufumi

出典表記例: 「Kazufumi Furuse, llcore (2026), github.com/furuse-kazufumi/llcore」